家系育种数据的探索性数据分析（EDA）

Sheng Luan

2026-01-05

在拿到一个新的育种数据集时，直接开始建模（如估算遗传参数）往往是危险的。探索性数据分析 (**Exploratory Data Analysis, EDA**) 是必不可少的一步。它可以帮助我们:

1. 了解数据的基本结构和质量（是否有缺失值、异常值）。
2. 查看变量的分布特征（是否正态、是否有偏）。
3. 初步探索变量间的关系（相关性、组间差异）。

本文将以一个水产家系育种数据集为例，展示如何利用 R 语言中的 `DataExplorer` 包和 `tidyverse` 系列工具，快速完成高质量的 EDA。

1. 准备工作

首先，我们需要加载必要的 R 包。* **`tidyverse`**: 数据科学的核心工具集（包含 `dplyr`, `ggplot2`, `tidyr` 等）。* **`DataExplorer`**: 专为自动化 EDA 设计的强大工具。* **`dtplyr`**: `data.table` 的 `dplyr` 后端，处理大数据集时更快（可选）。

```
library(dplyr)
library(dtplyr)
library(tidyr)
library(DataExplorer)
library(ggplot2)
```

2. 数据导入与初探

我们读取名为 `HXN2025.csv` 的数据集。

```
# 读入数据
hxn <- read.csv("HXN2025.csv", header = TRUE)

# 查看基本结构
str(hxn)
```

```
'data.frame':   7344 obs. of  7 variables:
 $ Fami: chr  "XNGS510912" "XNGS510912" "XNGS510912" "XNGS510912" ...
 $ ID  : chr  "XNGS510912_1" "XNGS510912_2" "XNGS510912_3" "XNGS510912_4" ...
 $ Seq : int  1 2 3 4 5 6 7 8 9 10 ...
 $ M1BW: num  2.15 2.15 2.15 2.15 2.15 2.15 2.15 2.15 2.15 2.15 ...
 $ Time: int  39 45 45 48 48 54 57 60 69 69 ...
 $ Tank: chr  "B4" "B4" "B4" "B4" ...
 $ Pop : chr  "Imm" "Imm" "Imm" "Imm" ...
```

从 `str()` 的输出可以看到: * 字符型变量 **(chr)**: `Fami` (家系), `ID` (个体号), `Tank` (测试池), `Pop` (群体)。 * 数值型变量 **(num/int)**: `M1BW` (入池体重), `Time` (存活时间)。

`DataExplorer` 提供了更直观的结构查看方式:

```r
plot_str(hxn, type="r")
```

`introduce()` 函数则能直接给出数据的“体检报告”:

```r
introduce(hxn)
```

```
  rows columns discrete_columns continuous_columns all_missing_columns
1 7344       7                4                  3                   0
  total_missing_values complete_rows total_observations memory_usage
1                    0          7344              51408       601160
```

3. 数据全景概览

`plot_intro()` 是我最喜欢的函数之一，它能生成一张包含变量类型分布、缺失值比例、完整行比例的仪表盘。

```r
plot_intro(hxn)
```

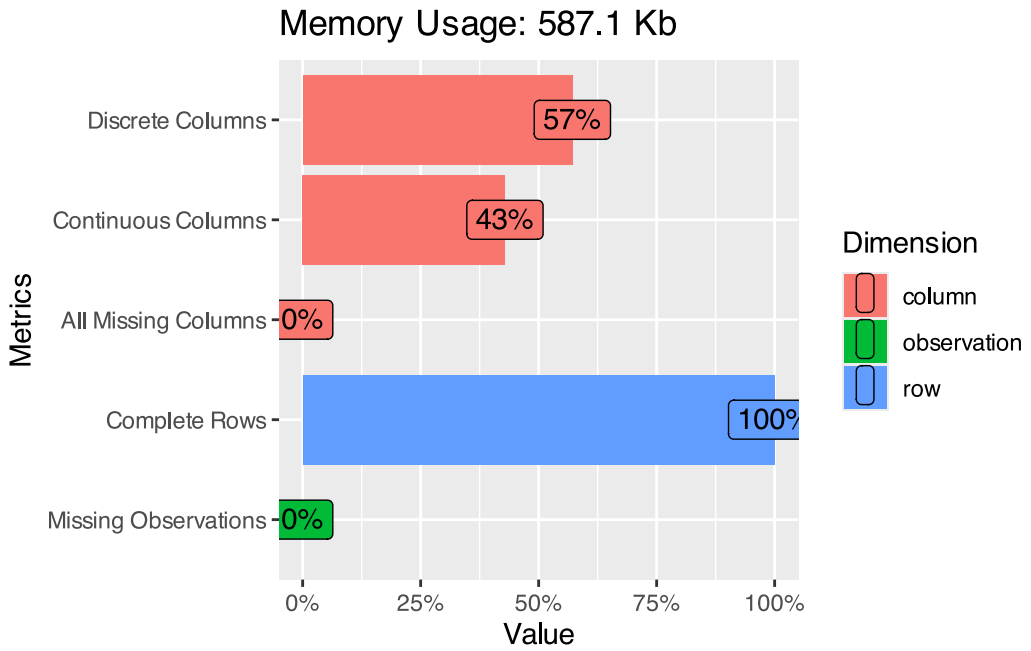

解读：这张图告诉我们数据质量非常高，没有缺失值。如果有缺失值，这里会显眼的标出红色区域，提示我们需要进行插补或剔除。

4. 单变量分析：分布与频次

离散变量 (Categorical)

对于分类变量（如群体、家系），我们关心的是样本量的平衡性。

```
# 查看各分类水平的频次
# maxcat = 100 确保显示所有家系（如果家系数量很多）
plot_bar(hxn, maxcat = 100)
```

```
1 columns ignored with more than 100 categories.
ID: 3752 categories
```

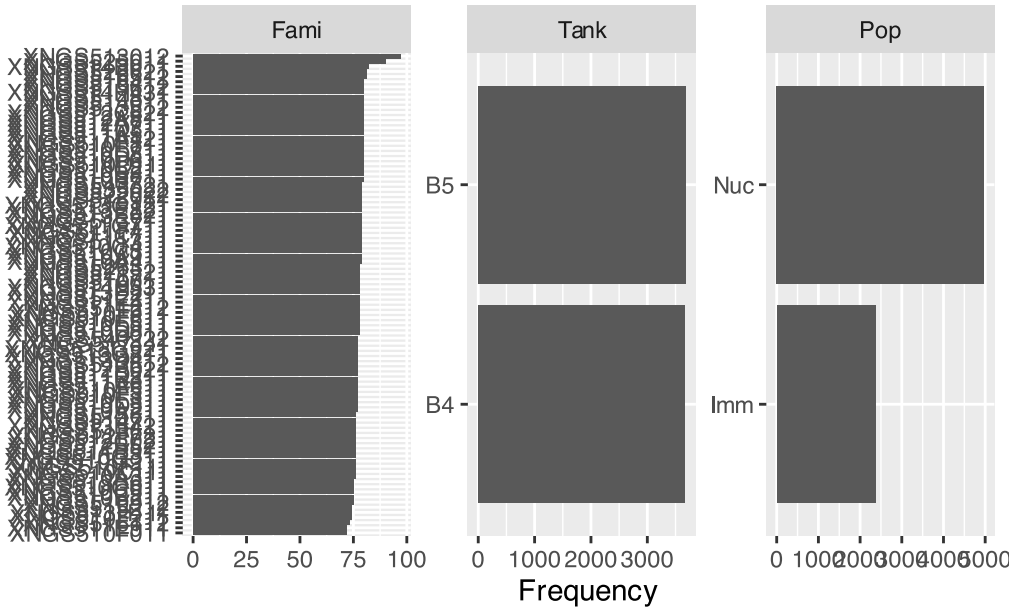

解读: * `Tank`: B4 和 B5 两个测试池的样本量基本一致。 * `Pop`: **Nuc** (核心群) 的个体数明显多于 **Imm** (外源群)。 * `Fami`: 大多数家系的测试个体数在 60-90 尾之间，但有少数家系超过 90 尾。

我们还可以通过 `by` 参数进行分组查看，例如查看不同群体在各测试池中的分布:

```
plot_bar(hxn, by="Pop", maxcat = 100)
```

```
1 columns ignored with more than 100 categories.
ID: 3752 categories
```

```
Warning: `aes_string()` was deprecated in ggplot2 3.0.0.
ℹ Please use tidy evaluation idioms with `aes()`.
ℹ See also `vignette("ggplot2-in-packages")` for more information.
ℹ The deprecated feature was likely used in the DataExplorer package.
  Please report the issue at
  <https://github.com/boxuancui/DataExplorer/issues>.
```

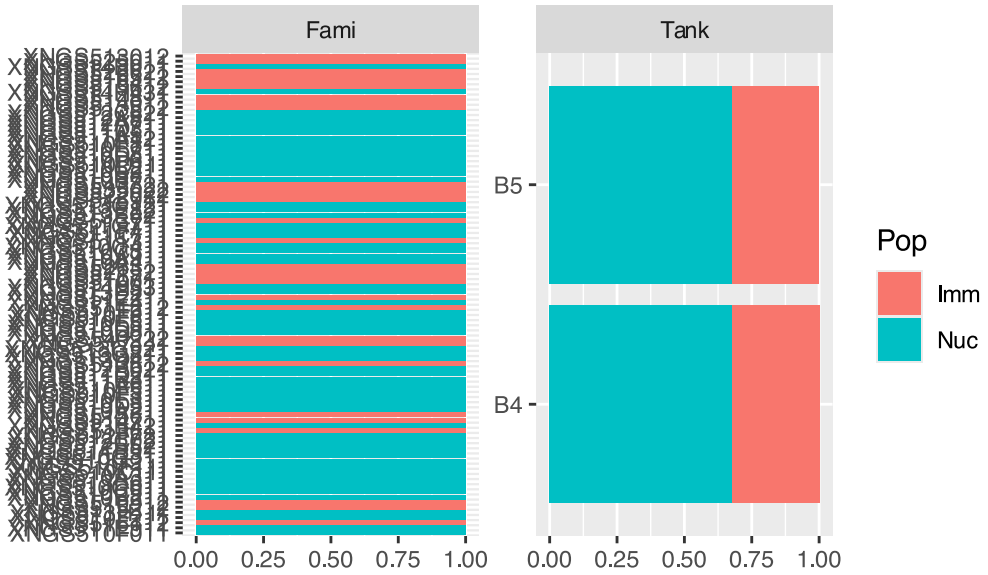

连续变量 (Continuous)

对于数值变量（体重、时间），我们关心的是分布形态（正态性、偏度）。

```
plot_histogram(hxn)
```

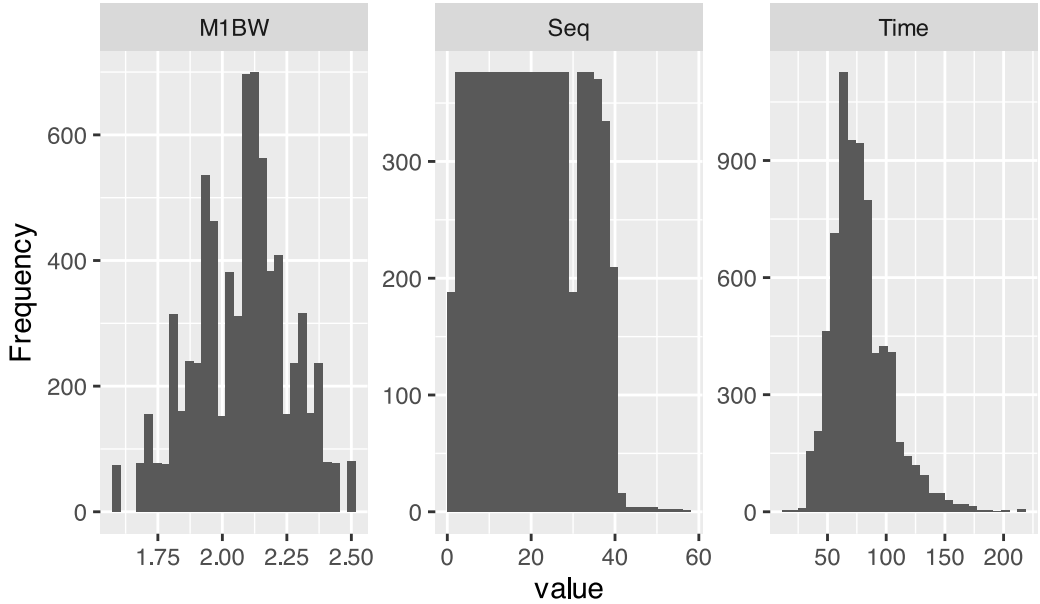

解读： * `M1BW` (体重): 近似正态分布，均值在 2g 左右。* `Time` (存活时间): 呈现右偏分布（长尾在右侧），峰值在 75 小时左右，说明小部分个体存活时间较长，但也有部分个体死亡较早。

正态性检验 (QQ Plot)

在进行遗传评估（如使用线性混合模型）前，我们需要检查数据是否大体符合正态分布假设。QQ 图（Quantile-Quantile Plot）是一个非常直观的标准诊断工具。

如何解读 **QQ** 图？ QQ 图将数据的实际分位数（y 轴）与理论正态分布的分位数（x 轴）进行对比。 * 理想情况： 如果数据完全服从正态分布，所有的点应该紧密地落在一条 **45** 度的对角直线上。 * 偏离情况： * 如果点呈现弯曲（香蕉状），说明数据分布是偏态的（如 `Time` 变量）。 * 如果两端的点偏离直线，说明数据存在长尾（极端值较多）。

为什么这很重要？ 许多统计方法（如 t 检验、ANOVA、BLUP 育种值估算）都假设数据（或其残差）服从正态分布。如果 QQ 图显示严重偏离（例如 `Time` 变量），我们可能需要对数据进行转换（如取对数、开方）或使用非参数方法，以确保分析结果的可靠性。

```
# 只选择感兴趣的数值变量进行检验
hxn |>
  select(M1BW, Time) |>
  plot_qq()
```

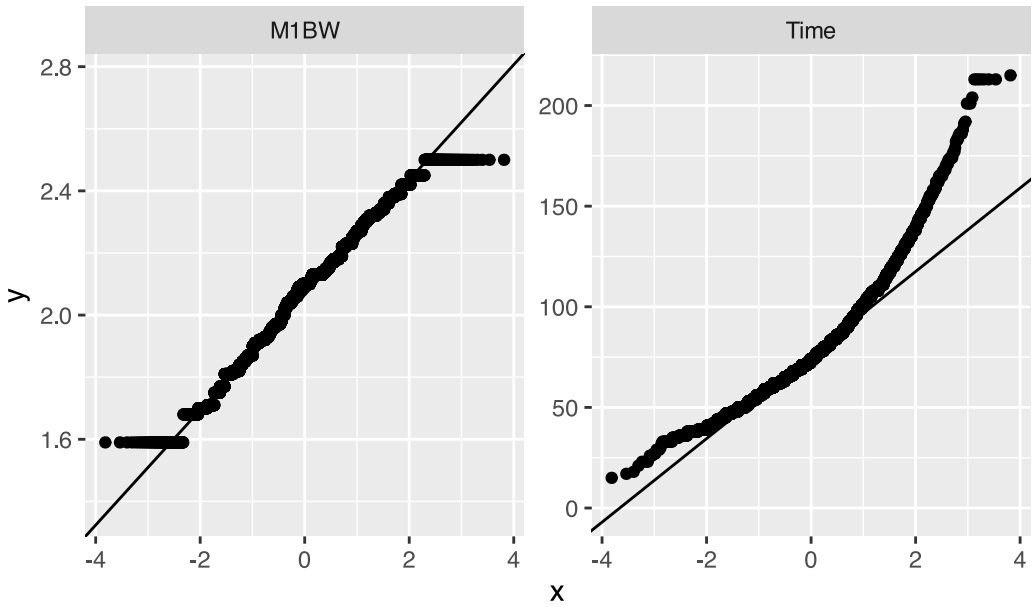

5. 双变量分析：相关性与差异

描述性统计

除了图形，我们往往还需要具体的统计数值来写入报告。下面计算各群体在不同性状上的均值 (Mean)、标准差 (SD) 和变异系数 (CV)。

```
summary_table <- hxn |>
  group_by(Pop) |>
  summarise(
    N = n(),
    BW_Mean = mean(M1BW, na.rm = TRUE),
    BW_SD = sd(M1BW, na.rm = TRUE),
    Time_Mean = mean(Time, na.rm = TRUE),
    Time_SD = sd(Time, na.rm = TRUE)
  ) |>
  mutate(
    BW_CV = round(BW_SD / BW_Mean * 100, 2),
    Time_CV = round(Time_SD / Time_Mean * 100, 2)
  )

# 使用 knitr::kable 输出美观的表格
knitr::kable(summary_table, digits = 2, caption = "不同群体的描述性统计")
```

Pop	N	BW_Mean	BW_SD	Time_Mean	Time_SD	BW_CV	Time_CV
Imm	2372	2.16	0.14	77.04	24.64	6.59	31.98
Nuc	4972	2.04	0.19	78.23	24.50	9.32	31.32

变量间的相关性

我们通常想知道性状之间是否存在关联。例如，入池体重 (`M1BW`) 是否会影响存活时间 (`Time`)？

```
plot_correlation(hxn, type=c("continuous"))
```

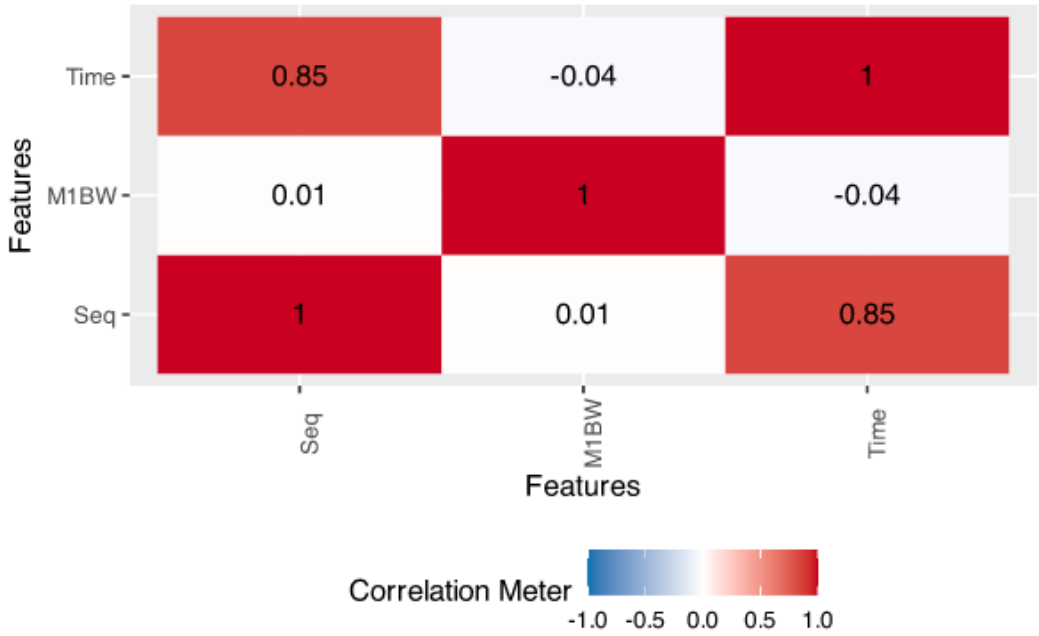

解读：热图显示 `M1BW` 和 `Time` 的相关系数接近 0。这意味着在当前实验条件下，个体的初始大小对其耐受性（存活时间）几乎没有影响。这是一个重要的生物学发现。

为了排除环境（测试池）效应的干扰，我们可以分测试池查看：

```
# 分测试池查看相关性
hxn |>
    filter(Tank == "B4") |>
    plot_correlation(type = c("continuous"), title = "Correlation in Tank B4")
```

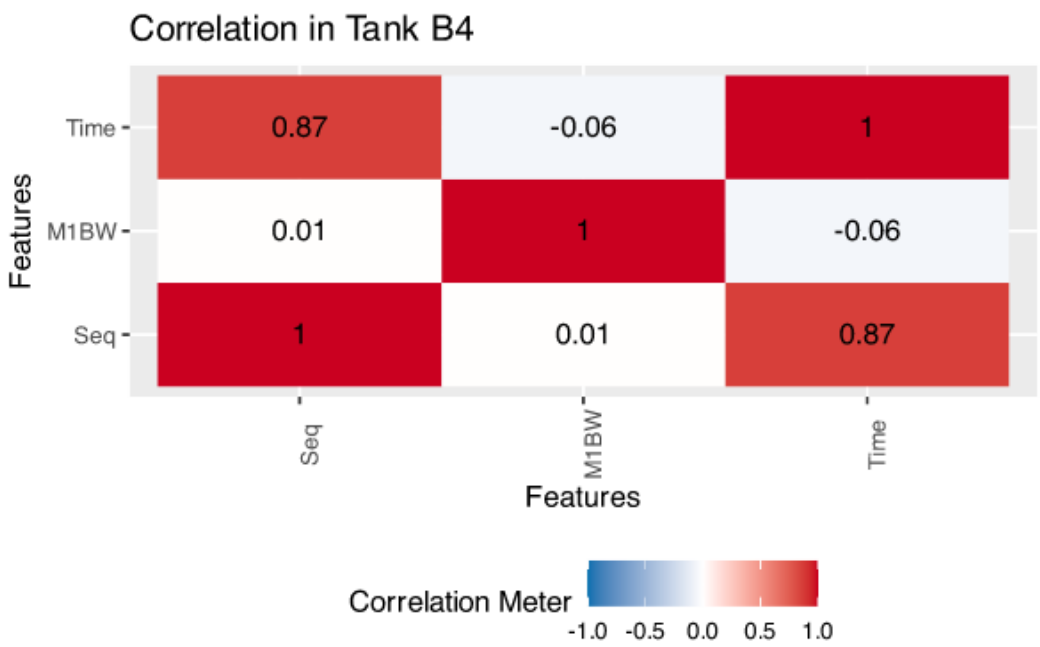


```
hxn |>
    filter(Tank == "B5") |>
    plot_correlation(type = c("continuous"), title = "Correlation in Tank B5")
```

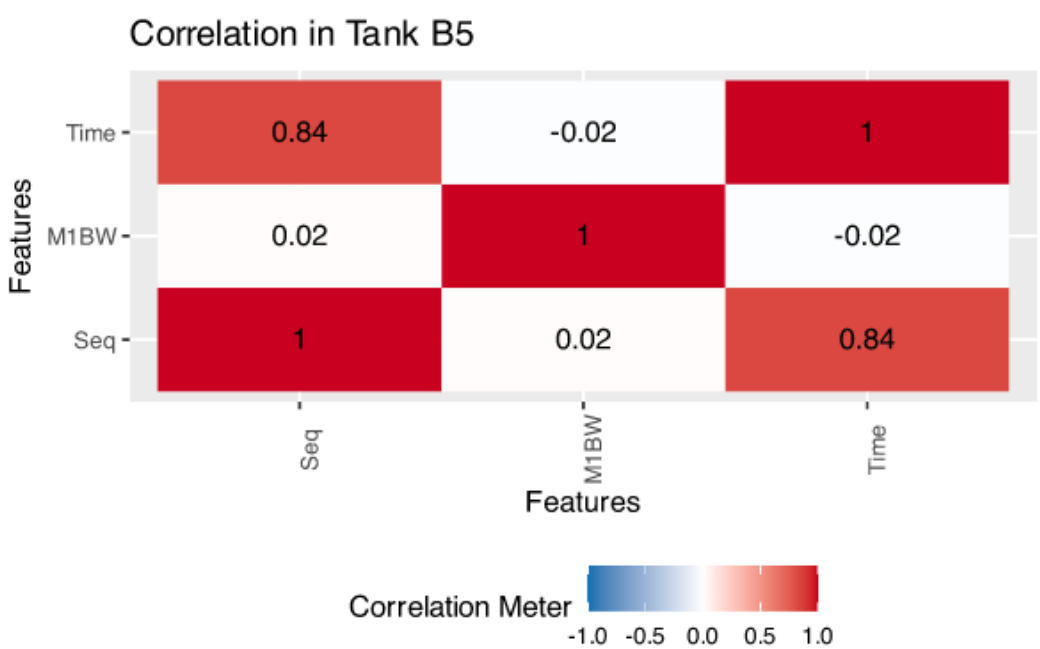

结论依然一致。

组间差异 (箱型图)

箱型图 (Boxplot) 是比较不同组别（如不同群体、不同家系）性状差异的神器。

不同群体的表现差异:

```
hxn |>
    select(M1BW, Time, Pop) |>
    plot_boxplot(by = "Pop")
```

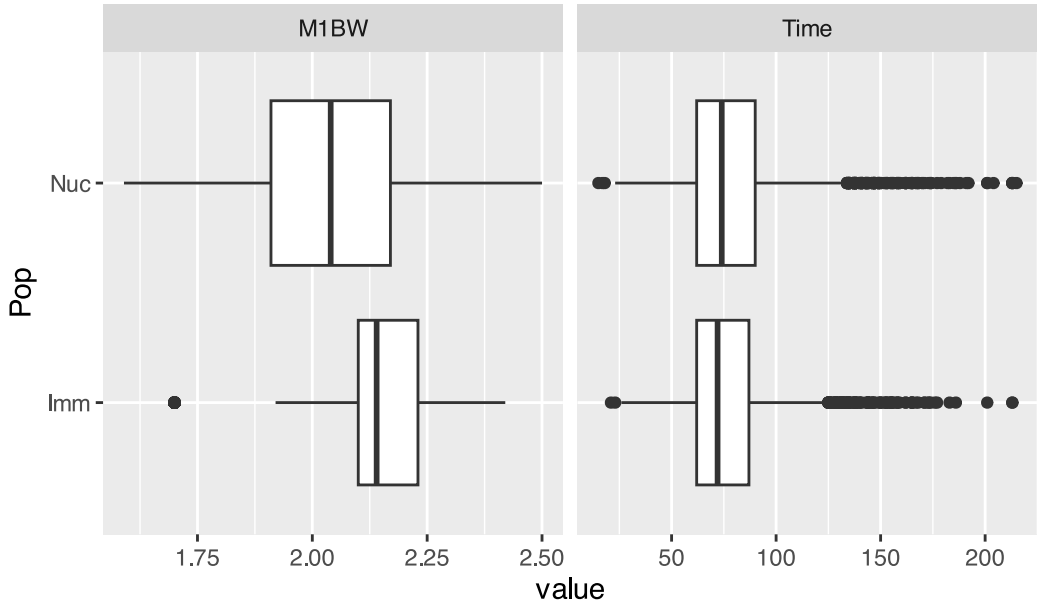

不同家系的存活时间差异:

```
hxn |>
    select(Fami, Time, Pop) |>
    plot_boxplot(by = "Fami")
```

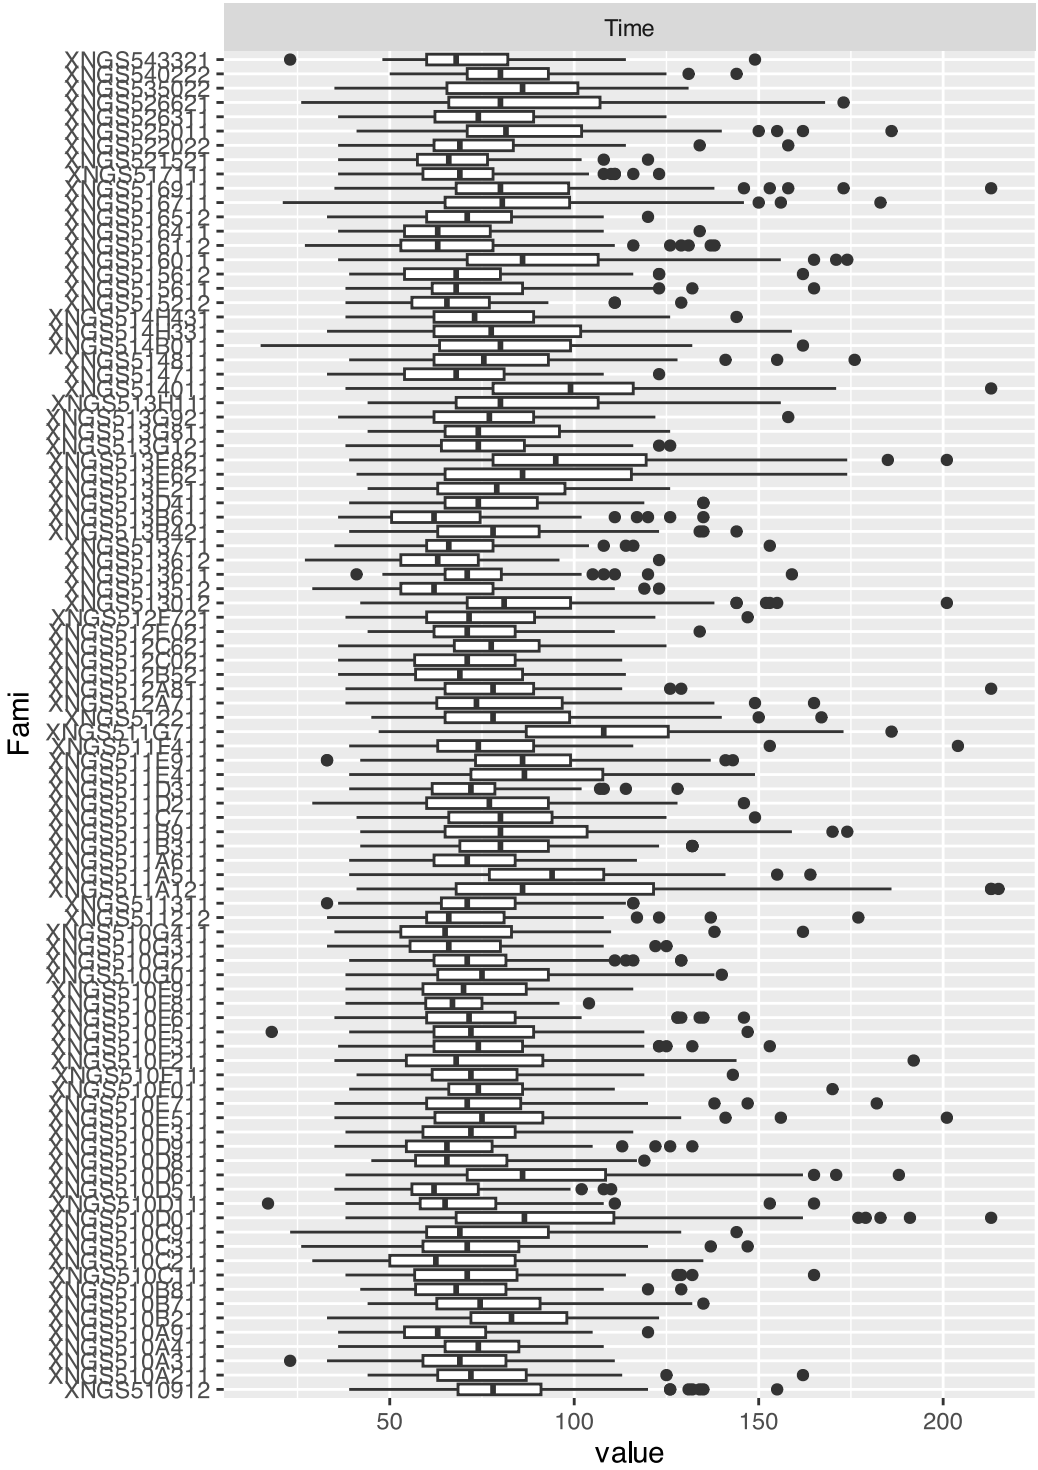

通过这张图，我们可以快速识别出哪些家系表现优异（中位线高），哪些家系表现较差。

6. 进阶分析：家系表型的一致性

在育种中，我们非常关心基因型与环境的互作 (GxE)。简单来说，就是同一个家系在不同环境（Tank B4 vs B5）下的表现是否一致？

这需要计算家系均值在两个测试池之间的相关性。`DataExplorer` 主要处理原始数据，对于这种特定的统计需求，我们需要结合 `dplyr` 和 `tidyr` 进行数据重塑（Reshape）。

步骤：1. **Summarize**: 计算每个家系在每个测试池内的平均存活时间。2. **Pivot**: 将数据从“长格式”转换为“宽格式”，让 B4 和 B5 变成两列。3. **Correlate & Plot**: 计算相关系数并绘图。

```r
# 1. 计算家系均值
family_tank_summary <- hxn |>
  group_by(Fami, Tank) |>
  summarise(Mean_Time = mean(Time, na.rm = TRUE), .groups = "drop")

# 2. 转换为宽格式
family_wide <- family_tank_summary |>
  pivot_wider(names_from = Tank, values_from = Mean_Time)

# 3. 计算相关系数
cor_val <- cor(family_wide$B4, family_wide$B5, use = "complete.obs")

# 4. 绘制散点图
ggplot(family_wide, aes(x = B4, y = B5)) +
  geom_point(alpha = 0.6, size = 3, color = "steelblue") +
  geom_smooth(method = "lm", color = "darkred", se = FALSE) +
  geom_text(aes(label = Fami), vjust = -0.5, size = 3, check_overlap = TRUE) +
  labs(
    title = paste("家系在不同测试池中的相关性 (r =", round(cor_val, 2), ")"),
    subtitle = "每个点代表一个家系",
    x = "Tank B4 平均存活时间 (h)",
    y = "Tank B5 平均存活时间 (h)"
  ) +
  theme_minimal()
```

```
`geom_smooth()` using formula = 'y ~ x'
```

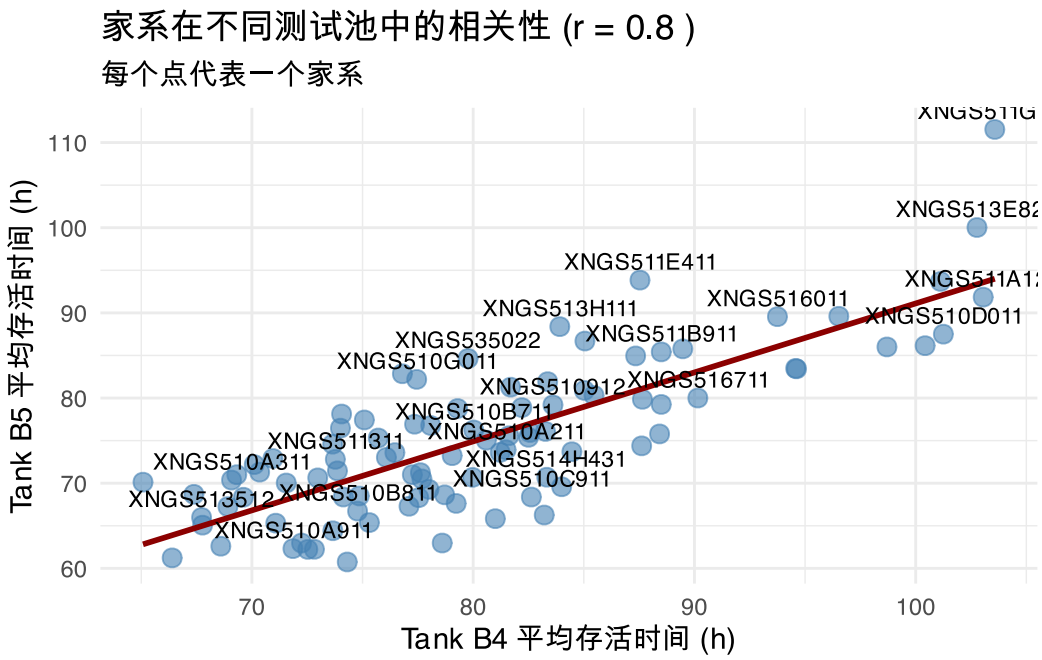

解读： 如果相关系数 r 很高（接近 1），说明家系在两个测试池中的表现非常一致，环境误差较小，数据可信度高。如果 r 很低，则可能存在较大的环境干扰或 GxE 效应。

总结

通过 `DataExplorer`，我们仅用几行代码就完成了对数据的全面体检。结合 `tidyverse` 的灵活处理，我们还能深入探讨更复杂的育种问题。这种 **"Overview first, zoom and filter, then details-on-demand"** 的分析流程，是高效数据科学工作的典范。